

Modelado Estadístico

Práctica: estimadores de Bayes, Empirical Bayes y STAN

1. EMPIRICAL BAYES

- Usar el dataset **Batting** del paquete **Lahman** (**playerID**, **H**, **AB**). Obtenga el número total de hits e intentos por jugador.
- ¿Elegiría como “mejor jugador” a quienes tienen promedio 1? ¿Por qué?
- Para jugadores con más de 1000 intentos, estime la distribución de promedios usando una Beta. Llámela Λ .
Sugerencia: use `fitdistr` de **MASS** o método de momentos.
- Fije la distribución del punto anterior como prior para los valores p_i (*verdadera* probabilidad de hit del jugador i). Para cada jugador, obtenga el estimador Bayes para p_i .
- Rankee los jugadores usando los estimadores Bayes p_i obtenidos.
- Grafique y compare la estimación frecuentista (p_i empírico) y la de Empirical Bayes para todos los jugadores.
- (Opcional) Construya un ranking alternativo usando $P(p_i > 0.3 \mid \text{datos})$ en lugar de la media posterior. ¿Cómo cambia el orden respecto al de (e)? Discuta qué ranking elegiría según la pregunta que se quiera responder y la función de pérdida implícita.

2. MODELADO CONJUNTO CON STAN

En el ejercicio anterior tratamos a AB_i como un input fijo, no informativo sobre p_i . Pero en los datos se observa una correlación positiva fuerte entre AB_i y p_i : a los jugadores que batean mejor les dan más turnos al bate (sesgo de supervivencia). Modelamos esa dependencia explícitamente y dejamos que AB aporte información sobre p .

Proponemos el modelo jerárquico:

$$\begin{aligned} p_i &\sim \text{Beta}(\alpha, \beta) \\ \log AB_i \mid p_i &\sim \mathcal{N}(a + b \logit(p_i), \sigma^2) \\ H_i \mid AB_i, p_i &\sim \text{Binomial}(AB_i, p_i) \end{aligned}$$

con hiperpriors débiles sobre $(\alpha, \beta, a, b, \sigma)$ (por ejemplo, exponenciales y normales anchas).

- Verifique empíricamente que AB y p no son independientes en los datos. Reporte alguna medida de asociación (correlación de Spearman entre AB_i y H_i/AB_i es razonable, filtrando jugadores con muy pocos intentos) y un gráfico de H/AB vs $\log AB$.
- Implemente el modelo en STAN. Por costo computacional, ajuste sobre una submuestra aleatoria de ~ 300 jugadores.
- Compare la media posterior de p_i bajo este modelo con el estimador Empirical Bayes ingenuo del ejercicio 1, $\hat{p}_i^{EB} = (\alpha_0 + H_i)/(\alpha_0 + \beta_0 + AB_i)$. Grafique un scatter y

colóreelo por $\log AB_i$. ¿Para qué tipo de jugadores difieren más los dos estimadores?
 ¿En qué dirección los corrige el modelo conjunto, y por qué?

3. TEÓRICO

- (a) Sea $\mathbf{X} = (X_1, \dots, X_n)$ una muestra aleatoria con distribución P_θ . Suponga una distribución a priori T para θ , con $T \sim \tau$. Sea $\delta_\Lambda(\mathbf{X})$ el estimador Bayes para θ . Si es insesgado, pruebe que

$$\mathbb{E}((\delta_\Lambda(\mathbf{X}) - T)^2) = 0.$$

- (b) Mostrar que $\bar{X}$ no es un estimador de Bayes de θ para ninguna distribución a priori Λ cuando $X|_{T=\theta} \sim N(\theta, 1)$ y se usa pérdida cuadrática.

4. CÁLCULO DE POSTERIORI

Sea una m.a. $X_1, \dots, X_n$ donde $X_i|_{\theta=\theta} \sim \mathcal{P}(\theta)$ y $\theta \sim \Gamma(r, \lambda)$, $r, \lambda > 0$.

- (a) Encontrar el estimador Bayes δ_Λ y calcular el riesgo de Bayes $r(\delta_\Lambda, \Lambda)$.
 (b) Mostrar que δ_Λ puede escribirse como un promedio ponderado entre $\bar{X}$ y $\frac{r}{\lambda}$. Interprete.