

Modelado Estadístico

Práctica: cuatro GLMs sobre datasets reales

Todos los GLM tienen la misma forma:

$$\mathbb{E}[Y \mid X] = g^{-1}(\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p),$$

donde g es la *función de link*. Cambia el likelihood (y por lo tanto el link natural), pero la receta es siempre la misma. En estos ejercicios ajustamos cuatro casos sobre datasets reales y comparamos qué cambia.

Funciones que vamos a usar:

- `lm()` — regresión Gaussian (base R).
- `glm(..., family = binomial)` — logística (base R).
- `glm(..., family = poisson)` — Poisson (base R).
- `betareg::betareg()` — regresión Beta.
- `broom::tidy(modelo)` — coeficientes como tibble.

1. GAUSSIAN — DIAMANTES

El dataset `diamonds` (incluido con `ggplot2`) tiene ~54 000 diamantes con precio, peso en quilates (`carat`), corte, color y claridad.

- (a) Cargar el dataset y explorar con un scatter de `carat` vs `price`. ¿Es razonable suponer una relación lineal entre las dos variables?
- (b) Replicar el scatter pero con ambos ejes en escala log (`scale_x_log10()`, `scale_y_log10()`). ¿Qué forma toma la relación ahora? Justificar por qué modelar $\log(\text{price})$ contra $\log(\text{carat})$ tiene sentido.
- (c) Antes de ajustar, convertir `cut`, `color` y `clarity` a factores *no ordenados* con `factor(., ordered = FALSE)` para que R use coding de tratamiento (cada nivel comparado con una referencia).
- (d) Ajustar el modelo `lm(log(price) ~ log(carat) + cut + color + clarity)` y mostrar el output con `summary()`.
- (e) Interpretar **cada tipo** de coeficiente:
 - El **intercept**: ¿qué diamante hipotético describe? Traducirlo a un precio en dólares con `exp()`.
 - $\log(\text{carat})$: si el peso se duplica, ¿cuántas veces más caro es el diamante?
 - Una de las categóricas (por ejemplo `cutIdeal` o `clarityIF`): ¿qué factor multiplicativo sobre el precio implica?

- Verificar que el signo de los coeficientes de `color` es coherente con que D es el mejor color (y por lo tanto la referencia), y que los de `clarity` son coherentes con que I1 es el peor.

2. LOGÍSTICA — TITANIC

El dataset `TitanicSurvival` (paquete `carData`) tiene 1309 pasajeros con: si sobrevivieron, sexo, edad, y clase del pasaje (1ra, 2da o 3ra).

- Cargar el dataset, filtrar filas sin edad, y convertir `survived` a 0/1.
- Ajustar `glm(survived ~ sex + age + passengerClass, family = binomial)` y mostrar el `summary()`.
- Mirar el signo y magnitud de los coeficientes. ¿Cuáles efectos aumentan $P(\text{sobrevivir})$ y cuáles la reducen? ¿La dirección de cada uno es coherente con lo que cuenta la historia (mujeres y niños primero, primera clase tenía mejor acceso a los botes)?
- Construir una grilla de predicción con `expand.grid()` sobre edades de 0 a 80, sexo y clase. Calcular las probabilidades con `predict(..., type = "response")`.
- Calcular $P(\text{sobrevivir})$ para algunos perfiles concretos: una mujer de 30 años en 1ra clase, un hombre de 30 en 3ra, un niño de 5 en 2da. ¿Cuáles son las diferencias más fuertes?
- Graficar las curvas resultantes con `geom_line()`, color por sexo y `linetype` por clase. ¿Qué forma tienen las curvas? ¿Por qué?

3. POISSON — HOME RUNS

Volvemos al `Batting` de la clase 1. Queremos predecir cuántos home runs hace un jugador en una temporada como función de cuántos turnos al bate tuvo y de la era.

- Filtrar `Batting` a temporadas con `AB >= 200` y `yearID >= 1980`.
- Ajustar una regresión Poisson con link log: `glm(HR ~ log(AB) + I(yearID - 2000), family = poisson)`. Justificar por qué `log(AB)` y no `AB`.
- Mostrar el `summary()` e interpretar los dos coeficientes principales:
 - `log(AB)`: ¿qué implica que el coeficiente sea distinto de 1? ¿Los HRs escalan exactamente con las oportunidades, o más rápido?
 - `I(yearID - 2000)`: ¿hay una tendencia temporal en la tasa de HRs? El coeficiente está en escala log, así que $e^{\hat{\beta}}$ es el factor multiplicativo por año.
- Graficar los datos (puntos) junto a la curva predicha. ¿Captura el modelo la tendencia general?

4. BETA REGRESSION — LA CURVA DE ENGEL

El dataset `FoodExpenditure` (paquete `betareg`) tiene 38 hogares con: `food` (gasto en comida), `income` (ingreso), y `persons` (cantidad de miembros). Queremos modelar la **proporción** del ingreso gastada en comida.

- Cargar `betareg::FoodExpenditure`. Crear la columna `prop = food / income`.
- Verificar que `prop` está en $(0, 1)$ con `summary(fe$prop)`.

- (c) Antes de ajustar: la Ley de Engel sostiene que a mayor ingreso, menor proporción del gasto destinado a necesidades básicas. ¿Qué signo se espera entonces para el coeficiente de `income`?
- (d) Ajustar el modelo con `betareg(prop ~ income + persons)`. ¿Qué link usa por default?
- (e) Interpretar los coeficientes. ¿Se cumple la predicción sobre el signo de `income`?
- (f) Graficar las predicciones: una curva por nivel de `persons` (1, 3, 5) en función del ingreso, superponiendo los datos.