Segundo bimestre de 2026 Clase 4 — Modelos Mixtos

Modelado Estadístico

Práctica: efectos aleatorios y *partial pooling* sobre los datos de radon

Trabajamos con los datos `radon` del paquete `rstanarm`: 919 mediciones de gas radon en viviendas de 85 *counties* de Minnesota. El radon es un gas radiactivo que se filtra desde el suelo y se acumula en los sótanos; nos interesa modelar `log_radon` (el log de la concentración medida) a partir de en qué piso se tomó la medición (`floor`: `0` = sótano, `1` = planta baja) y de cuánto uranio hay en el suelo del county (`log_uranium`, una variable **a nivel de grupo**: idéntica para todas las casas del mismo county). La variable de agrupamiento es `county`.

Tres maneras de tratar los *counties*. El problema es que hay counties con decenas de mediciones y otros con una sola. Tenemos tres opciones:

- **Sin pooling** (efectos fijos): un intercept libre por county (`lm(... ~ county - 1)`). Cada county se estima con sus propios datos y nada más ⇒ los counties con pocas casas dan estimaciones rabiosamente ruidosas.
- **Pooling total**: ignorar el county y ajustar un único intercept para todos. Estable, pero borra las diferencias reales entre counties.
- **Partial pooling** (efectos aleatorios): suponer que los intercepts de los counties vienen de una distribución común, $\alpha_j \sim \mathcal{N}(\mu, \tau^2)$, y estimar esa distribución junto con los datos. El modelo **aprende cuánto confiar en cada county**: los de muchos datos se quedan cerca de su promedio; los de pocos datos se *encogen* (*shrinkage*) hacia el promedio global. Es el punto medio entre los dos extremos.

Un modelo **mixto** combina efectos **fijos** (comunes a todos, como la pendiente de `floor`) con efectos **aleatorios** (que varían por grupo). Lo ajustamos con `lme4::lmer()`, con la sintaxis `(1 | county)` para intercepts aleatorios y `(1 + floor | county)` para intercepts y pendientes aleatorios.

---

1. **Exploración.** Para cada county, calcular el número de mediciones y el promedio de `log_radon`. Graficar el promedio en función del número de casos. ¿Qué les pasa a los promedios de los counties con pocas mediciones? ¿Por qué esto debería hacernos desconfiar de un modelo **sin pooling**?

2. **Efectos fijos (sin pooling).** Ajustar el modelo lineal sin intercept con un efecto fijo por county, `lm(log_radon ~ county - 1)`, y luego el que agrega la pendiente de `floor`, `lm(log_radon ~ county - 1 + floor)`. Comparar ambos con `anova`: ¿aporta `floor`? Interpretar el signo de su coeficiente: ¿es coherente con que el radon se acumula en los sótanos?

3. **Intercepts aleatorios (*partial pooling*).** Ajustar el modelo mixto más simple, `lmer(log_radon ~ (1 | county))`: un intercept global fijo más un desvío aleatorio por county. Del `summary()`, leer las dos componentes de varianza (τ^2 entre counties y σ^2 dentro de cada county) y calcular la **correlación intra-clase**

$$\text{ICC} = \frac{\tau^2}{\tau^2 + \sigma^2}.$$

Interpretarla: ¿qué fracción de la variabilidad total se explica por diferencias *entre* counties? Con `ranef()`, mirar los desvíos estimados por county.

4. **Agregar `floor` como efecto fijo.** Ajustar `lmer(log_radon ~ floor + (1 | county))`. Recalcular la ICC con las nuevas varianzas. Comparar el coeficiente de `floor` con el que obtuviste por efectos fijos en el ejercicio 2: ¿cambia mucho?

5. **Pendientes aleatorias.** Ajustar `lmer(log_radon ~ floor + (1 + floor | county))`, que deja que el efecto de `floor` **varíe por county**. ¿Qué nueva cantidad aparece en la parte de efectos aleatorios del `summary()` (además de la varianza de la pendiente)? Interpretar la correlación estimada entre intercept y pendiente.

6. **Predictor a nivel de grupo.** Agregar `log_uranium` como efecto fijo: `lmer(log_radon ~ floor + log_uranium + (1 + floor | county))`. Interpretar su signo. ¿Qué le pasa a la varianza *entre* counties (τ^2) al incluir esta variable, y por qué tiene sentido? Comparar los cuatro modelos mixtos con `anova`.

7. **El gráfico del *shrinkage*.** Para cada county, obtener el intercept estimado por el modelo **sin pooling** (ejercicio 2) y por el modelo de **intercepts aleatorios** (ejercicio 3). Graficarlos juntos, usando el número de mediciones del county como tamaño del punto. Verificar el fenómeno central de la clase: los counties con **pocos datos** son los que más se *encogen* hacia el promedio global, mientras que los de muchos datos casi no se mueven. Explicar por qué.

8. **Predecir un county nuevo.** Intentar predecir `log_radon` para un county que no aparece en los datos, primero con el modelo de efectos fijos del ejercicio 2 y luego con un modelo mixto (usando `allow.new.levels = TRUE`). ¿Cuál de los dos puede hacerlo y por qué? ¿Qué valor devuelve el modelo mixto para ese county desconocido?